

Construye tu propia base de datos

herramientas digitales para el análisis de textos
(6° edición)

Andrés Echavarría

Centre National de la Recherche Scientifique

Université Sorbonne Nouvelle

Escuela de doctorado

Universidad Complutense de Madrid





© 2026 International Crisis Group

Observar la dinámica

- ¿Qué está ocurriendo en este espacio?
- ¿Cómo podemos delimitar este acontecimiento?
- ¿Dónde termina la dinámica y dónde comienza nuestra observación?

La dinámica frente al dato

- **La dinámica:** La realidad es un flujo continuo, polifónico y complejo (ej. una manifestación popular, la recepción de un texto).
- **La intervención:** Para poder investigar, debemos aislar **unidades discretas** de ese continuo.
- **El dato como construcción:** El dato no preexiste a la mirada del investigador; es capturado (*capta*) bajo sesgos y preguntas teóricas concretas.

Drucker, J. (2011). "Humanities Approaches to Graphical Display". DHQ.

Editorialización (*entender lo digital como un espacio real*)

“ "La editorialización es el conjunto de dinámicas —interacciones de las acciones humanas con el entorno tecnológico— que producen y estructuran el espacio digital."

— **Marcello Vitali-Rosati** (2018)

”

Vitali-Rosati, M. (2018). On Editorialization.

El gesto de describir: entidades y atributos

Para organizar el conocimiento, dividimos el dominio en:

- **Entidad:** El concepto u objeto sustantivo que queremos estudiar (ej. un autor, un libro).
- **Atributo:** Las características específicas que definen o describen a esa entidad.
- **Tipo de dato:** El molde formal que la computadora impone a cada atributo para poder procesarlo racionalmente.

1. Primer ejemplo: describir una `persona`

Modelamos un autor o investigador de nuestro corpus:

- **Nombre:** Texto libre (`String`)
 - *Ejemplo:* `"Cervantes, Miguel de"`
- **Año de nacimiento:** Número entero (`Integer`)
 - *Ejemplo:* `1547` (permite ordenar cronológicamente)
- **¿Es de nacionalidad española?:** Lógico binario (`Boolean`)
 - *Ejemplo:* `True` (Verdadero)
- **Rol principal:** Opción cerrada (`Enum`)
 - *Ejemplo:* `Poeta` (de una lista: *Dramaturgo, Poeta, Novelista, Impresor*)

Explicación: ¿qué es un tipo de dato?

Es el molde formal que define qué clase de información almacena un atributo y qué operaciones lógicas o matemáticas puede realizar la computadora con ella:

- **Texto (String):** Cadenas libres de caracteres (letras, palabras, símbolos).
- **Entero (Integer):** Números sin decimales, útiles para contar o indexar.
- **Decimal (Float/Double):** Números con decimales (ej. coordenadas geográficas).
- **Booleano (Boolean):** Estados binarios excluyentes de Verdadero o Falso.
- **Enumerados (Enum):** Listas predefinidas y cerradas de opciones.

¿Qué es la modelización?

“ "La modelización consiste en producir una representación formalizada y simplificada de lo real para responder a una necesidad cognitiva o práctica específica."

— **M. Vitali-Rosati, B. Bachimont y P. Gançarski (2022)**

”

Vitali-Rosati, M. et al. (2022). "Modèles : du monde réel au monde numérique". Intelligibilité du numérique.

2. Segundo ejemplo: describir un libro

Modelamos las obras literarias de interés:

- **Título:** Texto libre (`String`)
 - *Ejemplo:* `"La Galatea"`
- **Número de páginas:** Número entero (`Integer`)
 - *Ejemplo:* `372`
- **¿Es manuscrito?:** Lógico binario (`Boolean`)
 - *Ejemplo:* `False` (Falso)
- **Lengua original:** Vocabulario controlado (`Enum`)
 - *Ejemplo:* `Español` (de una lista de códigos ISO: *ES*, *FR*, *IT*, *EN*)

3. Tercer ejemplo: describir un lugar

Modelamos la geografía de la producción literaria:

- **Nombre del municipio:** Texto libre (`String`)
 - *Ejemplo:* `"Alcalá de Henares"`
- **Coordenadas geográficas (latitud/longitud):** Números decimales (`Float/Double`)
 - *Ejemplo:* `40.481979` , `-3.363524`
- **País actual:** Código cerrado de país (`Enum/String`)
 - *Ejemplo:* `"ES"`

4. Cuarto ejemplo: describir una institución

Modelamos las editoriales o bibliotecas del corpus:

- **Nombre oficial:** Texto libre (`String`)
 - *Ejemplo:* `"Juan de la Cuesta"`
- **Año de fundación:** Número entero (`Integer`)
 - *Ejemplo:* `1604`
- **Tipo de institución:** Opciones predefinidas (`Enum`)
 - *Ejemplo:* `Imprenta` (de una lista: *Biblioteca, Imprenta, Universidad, Archivo*)

El problema del formato y la sintaxis (I): la ambigüedad del texto libre

¿Basta con asociar claves y valores de forma libre? El texto es flexible pero genera inconsistencias graves:

- **El caos ortográfico en fechas:**

- "10 de marzo de 1940" (español) vs. "March 10, 1940" (inglés).
- "10/03/1940": ¿10 de marzo (formato europeo) o 3 de octubre (formato anglosajón)?

- **La solución en bases de datos:** Usar el estándar ISO 8601 (AAAA-MM-DD).

- 1940-03-10 y 1940-10-03 son inequívocos y legibles por cualquier máquina. En SQL se representa bajo el tipo DATE .

El problema del formato y la sintaxis (II): el cálculo del tiempo y del espacio

- **El problema de almacenar estados variables:**
 - Si definimos `edad: 84` (ejemplo de Harper Lee), ¿hablamos de 84 años o 84 días? Además, la edad cambia constantemente.
 - **Principio de diseño:** No almacenes datos derivados o temporales. Almacena el dato inmutable (ej. `fecha_nacimiento`). El motor SQL calculará la edad dinámicamente al hacer la consulta.
- **La precisión espacial (coordenadas):**
 - En lugar de `"París"` (que puede ser París, Texas o París, Francia), usamos latitud y longitud.
 - Para evitar la pérdida de precisión, SQL ofrece tipos de datos decimales exactos como `DECIMAL(9,6)` o `NUMERIC`.

El problema del formato y la sintaxis (III): identificadores y no-cálculo

Regla de oro de las bases de datos: No todo lo que tiene números es un tipo de dato numérico en SQL.

- **¿Se pueden hacer operaciones matemáticas con el campo?**
 - Si la respuesta es **no**, no es un número.
 - **Ejemplos:** Códigos postales (`28015`), números de teléfono, códigos ISBN, identificadores DOI o ID autoincrementales.
- **El peligro de los ceros a la izquierda:**
 - Si almacenas el código postal de Barcelona `"08001"` como un entero (`INTEGER`), la máquina guardará `8001`, corrompiendo el dato.
 - **Solución:** Estos campos deben ser de tipo texto (`VARCHAR` o `TEXT` en SQL) para proteger su formato y caracteres especiales.

El problema del formato y la sintaxis (IV): correspondencia con tipos de datos SQL

Dato humano	Atributo propuesto	Tipo de dato SQL (SQLite/Postgres)	Operaciones permitidas
Nombre o título	nombre_autor	VARCHAR(255) o TEXT	Búsqueda por subcadena, ordenación
Páginas o año	paginas	INTEGER	Sumas, promedios, comparaciones
Coordenadas	latitud	DECIMAL(9,6) o REAL	Distancias geográficas, mapas
Código postal o ISBN	codigo_postal	VARCHAR(10) o TEXT	Indexación, coincidencia exacta
Fecha exacta	fecha_impresion	DATE	Ordenación cronológica, intervalos

El problema de la semántica e interoperabilidad

¿Cómo nos aseguramos de que nuestras claves signifiquen lo mismo para otros investigadores?

- **Vocabularios comunes:** Usar esquemas normalizados como **Dublin Core** o **DataCite**.
- **Traducción filológica:**
 - En lugar de un campo casero `nom`, usamos el estándar `dc:creator` (Creador).
 - En lugar de `fecha`, usamos `dc:date` (Fecha) o `dc:created` (Creado).
 - En lugar de `lugar`, usamos `dc:coverage` o `GeoLocation` (Datacite).

De las fichas aisladas al caos de la tabla única

Si intentamos registrar la información en una sola tabla plana (tipo Excel):

Título Libro	Autor (Persona)	Año Nac.	Lugar Nac.	Editorial	Tipo Edit.
<i>La Galatea</i>	M. de Cervantes	1547	Alcalá	Blas de Robles	Imprenta
<i>Don Quijote</i>	M. de Cervantes	1547	Alcalá	Juan de la Cuesta	Imprenta

- **Redundancia:** Repetimos los datos de Cervantes en cada libro.
- **Riesgo de inconsistencia:** Si corregimos la fecha de Cervantes en una fila pero no en otra, rompemos la integridad de la base de datos.

El modelo relacional al rescate

- **Separar entidades:** Creamos una tabla para **PERSONAS**, otra para **LIBROS** y otra para **EDITORIALES**.
- **Clave primaria (Primary Key - PK):** Un identificador único e inalterable para cada fila (ej. **ID_Persona = 1**).
- **Clave foránea (Foreign Key - FK):** Una columna en la tabla **LIBROS** que almacena el **ID** de su autor correspondiente.
- *La información de la persona se almacena una sola vez. Los libros solo guardan la clave de enlace.*

Ejercicio práctico: el diccionario de datos

Antes de programar, definimos la estructura exacta. Esto es el **Diccionario de Datos**:

Entidad: **LIBROS**

Nombre del campo	Tipo de dato	Restricción / propiedad	Descripción
id_libro	Entero (PK)	Único, Autoincremental	Clave primaria del libro
titulo	Texto (String)	Obligatorio	Título de la obra
paginas	Entero	Mayor que cero	Número de páginas físicas
fk_autor	Entero (FK)	Apunta a PERSONAS(id_persona)	Enlace lógico al autor

Tipos de relaciones (I): uno a muchos (1:N)

Un registro de la tabla A se asocia con muchos de la tabla B, pero cada registro de B solo se conecta con uno de A.

```
erDiagram
    AUTORES ||--o{ LIBROS : "escribe (1:N)"
```

Representación en tablas de la base de datos (SQL):

[Tabla: AUTORES]	[Tabla: LIBROS]
+-----+-----+	+-----+-----+-----+
id_autor nombre (PK)	id_libro titulo fk_autor (FK)
+-----+-----+	+-----+-----+-----+
1 Cervantes	10 Don Quijote 1 -> Cervantes
2 Lope de Vega	11 La Galatea 1 -> Cervantes
+-----+-----+	12 Fuenteovejuna 2 -> Lope de Vega
	+-----+-----+-----+

Tipos de relaciones (II): uno a uno (1:1)

Cada registro de la tabla A se conecta de forma exclusiva con un único registro de la tabla B.

```
erDiagram
    MANUSCRITOS ||--|| SIGNATURAS : "identifica (1:1)"
```

Representación en tablas de la base de datos (SQL):

[Tabla: MANUSCRITOS]			[Tabla: SIGNATURAS]		
id_manuscrito	titulo		id_signatura	fk_manuscrito	(FK, UNIQUE)
101	Mio Cid		MS-846	101	-> Mio Cid
102	Buen amor		MS-952	102	-> Buen amor

Tipos de relaciones (III): muchos a muchos (N:M)

Muchos registros de la tabla A se asocian con muchos de la tabla B. SQL exige una **tabla de unión** intermedia.

```
erDiagram
```

```
AUTORES ||--o{ AUTORIA : "tiene (1:N)"
```

```
LIBROS ||--o{ AUTORIA : "recibe (1:N)"
```

Representación en tablas de la base de datos (SQL):

[Tabla: AUTORES]	[Tabla: AUTORIA (Unión)]	[Tabla: LIBROS]
+-----+-----+	+-----+-----+	+-----+-----+
id_autor nombre	id_autor id_libro	id_libro titulo
+-----+-----+	+-----+-----+	+-----+-----+
1 Lope	1 10 Lope 10	Antología
2 Quevedo	2 10 Quev. 20	Buscón
+-----+-----+	2 20 Quev.	+-----+-----+
	+-----+-----+	

Ejercicio colectivo: diseñando tu diccionario de datos

Para definir el modelo conceptual de tu propia investigación, responde a estas preguntas clave:

1. **Entidad principal:** ¿Cuál es el objeto central de tu tesis? (ej. *Manuscritos, Poemas, Cartas, Editores*).
2. **Atributos inmutables:** ¿Qué características necesitas registrar? (ej. *título, fecha_envio, soporte*).
3. **Tipado SQL:** ¿A qué tipo físico corresponde cada atributo? (ej. `TEXT` para títulos, `INTEGER` para páginas, `DATE` para fechas exactas, `DECIMAL` para coordenadas).
4. **Restricciones de integridad:** ¿Qué campos son obligatorios (`NOT NULL`) o únicos (`UNIQUE`)?
5. **Relaciones y cardinalidad:** ¿Cómo se conecta tu entidad con otras del corpus? (1:1, 1:N, N:M) y ¿cuál es la clave foránea (`FK`)?

Tipos de datos SQL (I): cadenas de texto

Para representar texto libre, títulos, nombres o transcripciones en SQL, disponemos de tres moldes principales:

- **VARCHAR(N)** (*Variable Character* - caracteres variables): Almacena texto de longitud variable hasta un máximo de **N** caracteres. Si guardas **"Lope"**, solo ocupa 4 caracteres en disco. Es el tipo más usado para nombres, títulos y direcciones.
- **CHAR(N)** (*Character* - longitud fija): Siempre reserva exactamente **N** caracteres en disco. Si guardas **"Lope"** en un **CHAR(10)**, rellenará el resto con 6 espacios vacíos. Ideal solo para códigos fijos (ej. códigos de idioma como **'es'**, **'fr'**).
- **TEXT** o **CLOB** (*Character Large Object* - objeto de caracteres grande): Diseñado para textos masivos sin límite predefinido (ej. transcripción de un cantar de gesta, citas extensas o notas bibliográficas).

Tipos de datos SQL (II): valores numéricos

Para contabilizar, medir o geolocalizar, los números en SQL se dividen por su naturaleza exacta o aproximada:

- **INTEGER** o **INT** (entero): Números sin decimales. Se usa para contar páginas, años (**1605**), identificadores autoincrementales (**ID**) o tiradas de ejemplares.
- **DECIMAL(P, S)** o **NUMERIC** (decimal exacto): Evita errores de redondeo.
 - **P** (Precisión): Total de dígitos significativos.
 - **S** (Escala): Cuántos de esos dígitos son decimales.
 - *Ejemplo:* **DECIMAL(9,6)** para coordenadas geográficas (como **40.481979**).
- **FLOAT** o **REAL** (coma flotante aproximada): Números decimales representados de forma aproximada en binario. Son óptimos para cálculos científicos masivos y rápidos, pero pueden introducir ligeras variaciones en los últimos decimales. No recomendables para identificadores ni datos monetarios.

Tipos de datos SQL (III): fechas y tiempo

En humanidades, el registro temporal debe ser preciso para poder establecer cronologías e intervalos:

- **DATE** (fecha): Almacena exclusivamente una fecha del calendario en formato estándar **AAAA-MM-DD** (año-mes-día, ej. **1605-01-16**). No incluye horas.
- **TIME** (hora): Almacena solo la hora del día en formato **HH:MM:SS** (ej. **18:30:00**), sin fecha asociada.
- **TIMESTAMP** o **DATETIME** (*sello de tiempo*): Fusiona fecha y hora en una sola marca temporal (ej. **1936-07-18 05:00:00**). Útil para registrar acontecimientos exactos.
- **INTERVAL** (intervalo): Representa una duración o lapso temporal (ej. **"3 years 2 months"** o **"48 hours"**). Muy útil para calcular la duración del proceso de impresión o la vida útil de un manuscrito.

Tipos de datos SQL (IV): booleanos y binarios

Existen valores especiales para representar estados lógicos binarios o archivos completos adjuntos a la base de datos:

- **BOOLEAN** (lógico booleano): Solo admite dos valores posibles: **TRUE** (Verdadero) o **FALSE** (Falso). Es óptimo para caracterizaciones directas de tipo sí/no (ej. **es_manuscrito**, **es_anonimo**, **digitalizado**).
- **BLOB** (*Binary Large Object* - objeto binario grande): Almacena secuencias de bytes puros (archivos multimedia). Se usa cuando necesitas guardar la imagen de un manuscrito digitalizado, un audio o un archivo PDF directamente dentro de una celda de la base de datos.
 - *Recomendación de diseño*: En bases de datos grandes, suele ser mejor guardar la ruta del archivo como texto (**VARCHAR**) y almacenar los archivos en una carpeta del servidor.