

Nota: Este documento ha sido generado de forma automática a partir de la grabación del curso y resumido mediante Gemini 3.5 flash(medium) sin tener en cuenta ninguna casuística de las mencionadas en la sesión presencial.

Resumen del speech: herramientas digitales para el análisis de textos (6ª edición)

Curso: Herramientas digitales para el análisis de textos

Entidad: Escuela de Doctorado, Universidad Complutense de Madrid

Docente: Andrés Echavarría

1. Epistemología: ¿qué es un "dato" en humanidades?

El primer paso metodológico antes de interactuar con un ordenador es epistemológico. En el ámbito de las humanidades digitales, debemos cuestionar la naturaleza de la información. Un dato no es una entidad neutra o natural que se recoge objetivamente del mundo real.

La realidad empírica es un flujo continuo, polifónico e infinitamente complejo (como una correspondencia epistolar histórica o el proceso de recepción de una corriente literaria). Para investigar, el humanista debe realizar una intervención sobre este flujo, recortando unidades discretas y aisladas bajo sus propias preguntas de investigación. Por ello, Johanna Drucker (2011) propone que en humanidades no trabajamos con *datos* (lo dado), sino con *capta* (lo capturado, seleccionado e interpretado por la mirada del investigador).

Esta estructuración ocurre en un espacio digital que tampoco es neutro. La **editorialización** representa el conjunto de dinámicas tecnológicas y humanas que producen, estructuran y confieren autoridad al espacio digital (Marcello Vitali-Rosati, 2018). Crear una base de datos es, por tanto, un acto interpretativo y situado.

2. ¿Qué es modelizar y por qué importa?

Para un humanista, la palabra "modelización" suele sonar abstracta o propia de las ciencias exactas. Sin embargo, en nuestro contexto es un proceso directo:

Modelizar consiste en producir una representación formalizada y simplificada de lo real para responder a una necesidad cognitiva o práctica específica.

— M. Vitali-Rosati, B. Bachimont y P. Gançarski (2022)

Modelar es la descripción formal de las variables que componen un objeto de estudio. Definir formalmente las formas y estructuras antes de proceder a llenar tablas y datos es fundamental para evitar la inconsistencia informática y, sobre todo, **para evitar repetir trabajos** (el doble esfuerzo de limpiar bases de datos mal estructuradas).

La pesadilla del doble trabajo (El caos del Excel plano)

El impulso común de abrir una hoja de Excel e introducir datos inmediatamente suele derivar en inconsistencias graves al cabo de unos meses. Por ejemplo: registrar múltiples autores en una misma celda (ej. "Lope de Vega, Quevedo") impide realizar búsquedas individuales limpias; introducir fechas en formato libre (ej. "hacia 1610?", "s. XVII") imposibilita la ordenación cronológica; y cometer erratas u homónimos (ej. "Cervantes" frente a "Miguel de Cervantes") fragmenta las consultas.

Cuando esto ocurre, el investigador se ve obligado a rehacer su trabajo y limpiar los datos de forma manual registro por registro. Diseñar la estructura de forma previa previene este doble esfuerzo.

3. Ladrillos del modelo: entidades y atributos

En el modelo relacional, estructuramos la información separándola en dos componentes lógicos:

- **Entidad (¿Qué cosas estudio?):** Representa el objeto o concepto general en sustantivo (ej. una `Persona`, un `Libro`, un `Lugar` o una `Institución`). Cada entidad se traduce físicamente en una **tabla** independiente.
- **Atributo (¿Qué características tienen esas cosas?):**** Representa las variables específicas del objeto (ej. título, año, páginas, coordenadas). Se traduce físicamente en las columnas de la tabla.

A cada atributo se le impone un tipo de dato conceptual que sirve de molde formal para la computadora: texto (*String*) para palabras, entero (*Integer*) para números sin decimales, decimal (*Float/Decimal*) para mediciones precisas, booleano (*Boolean*) para estados lógicos Verdadero/Falso, y enumerado (*Enum*) para listas cerradas de opciones.

Ejemplos de modelización conceptual

- Entidad **PERSONA** : Nombre (Texto, ej. "Cervantes, Miguel de"), Año de nacimiento (Entero, ej. 1547), ¿Nacionalidad española? (Booleano, ej. True), Rol principal (Enum, ej. "Poeta").
- Entidad **LIBRO** : Título (Texto, ej. "La Galatea"), Páginas (Entero, ej. 372), ¿Es manuscrito? (Booleano, ej. False).
- Entidad **LUGAR** : Nombre (Texto, ej. "Alcalá de Henares"), Latitud/Longitud (Decimales exactos, ej. 40.481979, -3.363524), Código de país (Texto de dos letras, ej. "ES").
- Entidad **INSTITUCION** : Nombre oficial (Texto, ej. "Juan de la Cuesta"), Año de fundación (Entero, ej. 1604), Tipo (Enum, ej. "Imprenta").

4. El control del formato, la sintaxis y la semántica

Para asegurar que nuestra base de datos sea consistente y pueda dialogar con otras, aplicamos normas de normalización:

- Normalización de fechas (ISO 8601): Evitamos la ambigüedad regional de formatos como 10/03/1940. Se impone el estándar internacional AAAA-MM-DD (ej. 1940-03-10), que en SQL corresponde al tipo nativo DATE.
- Inmutabilidad: Almacenamos datos estables (fecha de nacimiento) y evitamos datos variables (edad). La edad se calcula mediante consultas en tiempo de ejecución.
- Regla del no-cálculo para números: Si un atributo numérico no se va a usar para realizar cálculos aritméticos (sumas, promedios), **no es un número; es texto**. Códigos postales, teléfonos e ISBNs deben guardarse como texto (VARCHAR). Si guardas el código postal de Barcelona "08001" como un número entero, la computadora borrará el cero a la izquierda y guardará 8001, corrompiendo el dato.
- Semántica e interoperabilidad: Mapeamos nuestras columnas a esquemas de metadatos estándar como Dublin Core para que la base de datos sea legible por otros sistemas (ej. mapear autor a dc:creator y fecha a dc:date).

5. Estructura relacional: superando la tabla única

Intentar guardar un corpus complejo en una sola tabla plana de Excel obliga a duplicar datos (redundancia) y genera anomalías de actualización. El modelo relacional (Edgar F. Codd,

1970) resuelve esto dividiendo el diseño en tablas conectadas:

- **Clave primaria (Primary Key - PK):** Identificador numérico único y estable para cada registro de una tabla (ej. `id_persona = 1`).
- **Clave foránea (Foreign Key - FK):** ** Columna en la tabla secundaria que almacena la PK de la tabla principal con la que se relaciona (ej. `fk_autor` en `LIBROS` que apunta a `PERSONAS(id_persona)`).

El Diccionario de Datos es el mapa técnico que describe formalmente estas claves, nombres de campos, tipos físicos y restricciones (como obligatoriedad: `NOT NULL`) antes de programar la base de datos.

Tipos de relaciones y cardinalidades

1. **Relación uno a muchos (1:N):** Un registro de la Tabla A se conecta con muchos de la Tabla B, pero cada registro de B pertenece a uno solo de A. Ej: Un autor escribe muchos libros, pero un libro tiene un único autor principal.
2. **Relación uno a uno (1:1):** Relación biyectiva exclusiva. Ej: Un manuscrito físico tiene una única signatura topográfica de catálogo. Se asegura aplicando la restricción `UNIQUE` en la clave foránea.
3. **Relación muchos a muchos (N:M):** Muchos registros de A se conectan con muchos de B (ej. obras escritas en colaboración). Requiere crear una tabla de unión intermedia (ej. `AUTORIA`) que guarda las parejas de identificadores (`id_autor`, `id_libro`).

6. Glosario de tipos de datos en SQL

Al implementar físicamente las tablas en SQL, mapeamos los atributos a tipos físicos estructurados:

A. Cadenas de texto

- `'VARCHAR(N)'` (*Variable Character* - caracteres variables): Almacena texto de longitud variable hasta un máximo de `N` caracteres. Es eficiente en disco porque solo ocupa los caracteres reales escritos.
- `'CHAR(N)'` (*Character* - longitud fija): Siempre consume los `N` caracteres especificados, rellenando con espacios en blanco a la derecha si es más corto. Se limita a códigos fijos (ej. códigos ISO de países `'ES'`).

- ``TEXT`` / ``CLOB`` (*Character Large Object*): Diseñado para textos extensos sin límites (transcripciones completas, citas o comentarios literarios largos).

La analogía de la maleta vs. la caja rígida:

`VARCHAR` funciona como una maleta expandible que se encoge ocupando solo el tamaño de la ropa real que metes. `CHAR` es como una caja rígida de madera que siempre ocupa el mismo espacio de almacenamiento en el disco duro, aunque solo guardes un calcetín dentro.

B. Valores numéricos

- ``INTEGER`` / ``INT`` (entero): Números sin decimales. Utilizado para contar unidades físicas (páginas), años y claves identificadoras.
- ``DECIMAL(P, S)`` / ``NUMERIC`` (decimal exacto): Conserva la precisión matemática exacta sin errores de redondeo de la máquina en binario. `P` (Precisión) es el total de dígitos significativos y `S` (Escala) los dígitos decimales. Es indispensable para coordenadas de mapas (ej. `DECIMAL(9, 6)`).
- ``FLOAT`` / ``REAL`` (coma flotante aproximada): Representación binaria aproximada. Es veloz para cálculos matemáticos masivos pero puede introducir pequeñas variaciones en el último decimal. Debe evitarse para coordenadas geográficas precisas e identificadores.

C. Fechas y tiempo

- ``DATE``: Almacena exclusivamente una fecha del calendario en formato `AAAA-MM-DD`.
- ``TIME``: Almacena la hora del día en formato `HH:MM:SS`.
- ``TIMESTAMP`` / ``DATETIME`` (sello de tiempo): Fusiona fecha y hora exacta en una sola celda.
- ``INTERVAL``: Mide una duración o lapso temporal (ej. `"3 years 2 months"`).

D. Valores lógicos y binarios

- ``BOOLEAN``: Solo admite `TRUE` (Verdadero) o `FALSE`` (Falso). Evita inconsistencias ortográficas de entrada de datos.
- ``BLOB`` (*Binary Large Object*): Permite almacenar archivos binarios (imágenes digitalizadas de manuscritos, PDFs) directamente dentro de una celda.

Recomendación de diseño: Guardar archivos pesados directamente en tablas de base de datos hace que el sistema se vuelva sumamente lento y difícil de respaldar. La buena práctica es guardar las imágenes físicas en una carpeta de tu servidor u ordenador y registrar únicamente la ruta o enlace en la base de datos usando un campo de texto de tipo `VARCHAR`.

7. Ejercicio práctico: diseño del diccionario de datos conceptual

Para mañana, cada investigador debe responder a cinco preguntas clave sobre su propio tema de tesis para diseñar su Diccionario de Datos conceptual:

1. Entidad principal: ¿Cuál es el objeto central de tu tesis? (ej. manuscritos, cartas, poemas).
2. Atributos obligatorios: ¿Qué variables necesitas registrar de él? (ej. título, remitente, soporte).
3. Tipado SQL: ¿A qué tipo físico del glosario corresponde cada uno? (ej. `VARCHAR`, `INTEGER`, `DATE`, `DECIMAL`).
4. Restricciones: ¿Cuáles son indispensables (`NOT NULL`) y cuáles únicos (`UNIQUE`)?
5. Relaciones: ¿Cómo se conecta con otras tablas? (1:1, 1:N, N:M) y ¿cuál es la clave foránea (`FK`)?

8. Referencias académicas de consulta

1. Codd, E. F. (1970). "A Relational Model of Data for Large Shared Data Banks". *Communications of the ACM*, 13(6).
2. Dourish, P. (2017). *The Stuff of Bits: An Essay on the Materialities of Information*. MIT Press.
3. Drucker, J. (2011). "Humanities Approaches to Graphical Display". *Digital Humanities Quarterly (DHQ)*, 5(1).
4. Flanders, J., & Jannidis, F. (Eds.). (2018). *The Shape of Data in Digital Humanities: Modeling Texts and Textual Phenomena*. Routledge.
5. Vitali-Rosati, M. (2018). *On Editorialization: Structuring Space and Authority in the Digital Age*. Routledge.
6. Wilkinson, M. et al. (2016). "The FAIR Guiding Principles for scientific data management and stewardship". *Scientific Data*, 3.